

Proyecto Final

# DETECCIÓN DE FRAUDE

Emma Alicia Jiménez Sánchez  
Nancy Elena del Valle Vera  
Leonardo Rafael Ortiz Cervantes

# Justificación del Problema

---

El fraude financiero es uno de los delitos **más frecuentes y de mayor impacto económico** en la actualidad.


Busca analizar **patrones de comportamiento** para identificar actividades fraudulentas mediante técnicas de minería de datos y aprendizaje automático.

La detección temprana de fraudes puede reducir pérdidas económicas, proteger a los usuarios y fortalecer la confianza en los servicios financieros.



# Fraud Detection Dynamics: Financial Transaction.

---



Debido a la naturaleza sensible y confidencial de la información financiera, no fue posible encontrar bases de datos públicas mexicanas que permitieran un buen desarrollo de este proyecto.

El dataset elegido contiene aproximadamente **6 millones de registros** de transacciones financieras, lo que permite trabajar con una escala cercana a escenarios reales de operación bancaria.


# Análisis Exploratorio de Datos (EDA)

El dataset está compuesta por **6,362,620** registros y **11 variables**.


Dado que no existen valores faltantes ni repetidos, no fue necesario aplicar técnicas de imputación o eliminación de observaciones. Esto indica que el conjunto de datos presenta una calidad adecuada para realizar los análisis.

| Variable       | Tipo       | Descripción                                                            |
|----------------|------------|------------------------------------------------------------------------|
| step           | Numérica   | Unidad temporal de la simulación, donde cada paso representa una hora. |
| type           | Categórica | Tipo de transacción realizada.                                         |
| amount         | Numérica   | Monto de la transacción.                                               |
| nameOrig       | Categórica | Identificador de la cuenta de origen.                                  |
| oldbalanceOrig | Numérica   | Saldo de la cuenta de origen antes de la transacción.                  |
| newbalanceOrig | Numérica   | Saldo de la cuenta de origen después de la transacción.                |
| nameDest       | Categórica | Identificador de la cuenta destino.                                    |
| oldbalanceDest | Numérica   | Saldo de la cuenta destino antes de la transacción.                    |
| newbalanceDest | Numérica   | Saldo de la cuenta destino después de la transacción.                  |
| isFraud        | Binaria    | Indica si la transacción fue fraudulenta.                              |
| isFlaggedFraud | Binaria    | Indicador de fraude generado por reglas del sistema.                   |


# Detección de valores atípicos




# Detección de valores atípicos



# Detección de valores atípicos




# Detección de valores atípicos






# Detección de valores atípicos




# Distribución de las variables numéricas

La variable **amount** presenta una elevada frecuencia de transacciones de montos relativamente pequeños, mientras que las operaciones de gran volumen son menos comunes.




# Distribución de las variables numéricas

Para la variable **oldbalanceOrg**, el análisis indica que una gran proporción de las cuentas posee saldos relativamente bajos, mientras que un número reducido concentra cantidades significativamente mayores.





# Distribución de las variables numéricas

En el caso de **newbalanceOrig**, se observa una reducción general de los saldos después de las transacciones, comportamiento esperado debido a la salida de recursos desde las cuentas de origen.



# Distribución de las variables numéricas

Las variables **oldbalanceDest** y **newbalanceDest** presentan distribuciones muy similares, porque muchas de las cuentas receptoras ya poseen saldos elevados por lo que el monto transferido representa únicamente una pequeña proporción de su balance total.




# Relaciones entre variables

Las correlaciones más fuertes se observaron entre:


- **oldbalanceDest y newbalanceDest** (0.94).
- **oldbalanceOrig y newbalanceOrig** (0.80).
- **amount y newbalanceDest** (0.67).
- **amount y oldbalanceDest** (0.60).

Por otro lado, las variables relacionadas con fraude presentan correlaciones lineales bajas con el resto de las variables.




# Balance de clases

La variable objetivo **isFraud** presenta un fuerte desbalance de clases. Del total de transacciones registradas, aproximadamente el 99.87 % corresponde a operaciones legítimas, mientras que únicamente el 0.1291% se encuentra etiquetado como fraude.




# Análisis de variables categóricas

Se observó que las transacciones de tipo **CASH\_OUT** representan la categoría con mayor frecuencia, seguidas por **PAYMENT** y **CASH\_IN**.







# Análisis de variables categóricas




# Análisis de Transferencias



# Análisis de Transferencias



# Análisis de Transferencias



# Modelo No Supervisado : Clustering

Se excluyeron las variables de **nameOrig**, **nameDest** e **isFraud**, ya que con esto el modelo podría estar cayendo en un sobreajuste.

Se realizó la normalización y estandarización de las variables numéricas debido a la gran disparidad en los montos de las transacciones, se omitió la etiqueta y se eliminaron las identidades de las cuentas. Este filtrado permite un entrenamiento más rápido y una mejor capacidad de generalización.

| Variable       | Tipo       |
|----------------|------------|
| step           | Numérica   |
| type           | Categórica |
| amount         | Numérica   |
| oldbalanceOrg  | Numérica   |
| newbalanceOrig | Numérica   |
| oldbalanceDest | Numérica   |
| newbalanceDest | Numérica   |
| isFlaggedFraud | Binaria    |

# Modelo No Supervisado : Clustering

---

## Algoritmo elegido: MiniBatch K-Means

- Dataset de más de 6 millones de transacciones.
- Menor consumo de memoria que K-Means tradicional.
- Entrenamiento más rápido mediante lotes (mini-batches).
- Permite actualizar el modelo con nuevos datos sin reentrenarlo completamente.

## Ventajas

- Escalable para grandes volúmenes de información.
- Adecuado para escenarios de monitoreo continuo.
- Cercano a condiciones reales de operación bancaria.


# Modelo No Supervisado : Clustering

Evaluación del modelo:

| Métrica                | Resultado   | Interpretación                                 |
|------------------------|-------------|------------------------------------------------|
| Coeficiente de Silueta | 6.903       | Buena separación entre grupos.                 |
| Davies-Bouldin         | 8.070       | Clústeres compactos y bien definidos.          |
| Inercia (WCSS)         | 588,564,096 | Influenciada por la gran dispersión de montos. |

# Modelo No Supervisado : Clustering

Visualización de  
grupos (con PCA):





# Modelo Supervisado : Clasificación

---

## **Variable Objetivo:** isFraud

- 0 = Transacción legítima
- 1 = Transacción fraudulenta

## **Variables utilizadas**

- step
- type
- amount
- oldbalanceOrg
- newbalanceOrig
- oldbalanceDest
- newbalanceDest

# Modelo Supervisado : Clasificación

---

## Preprocesamiento

- One-Hot Encoding para **type**.
- Transformación logarítmica en variables monetarias.
- Estandarización con StandardScaler.
- Manejo del desbalance mediante:  
**class\_weight='balanced'**

## División del DataSet

- 80% Entrenamiento
- 20% Prueba
- Semilla fija para garantizar reproducibilidad:  
**random\_state = 42**
- Estratificación para conservar la proporción de fraudes: **stratify=y**.

# Modelo Supervisado : Clasificación

## Modelo Seleccionado: Random Forest Classifier

- Maneja relaciones no lineales.
- Robusto ante valores atípicos.
- Funciona bien con variables numéricas y categóricas.
- Buen desempeño en problemas desbalanceados.

| Parámetro   | Valores  |
|-------------|----------|
| n_estimator | 100, 200 |
| max_depth   | 10, 20   |

Se usó **GridSearchCV** para una validación cruzada estratificada (5 folds) con una configuración de 4 combinaciones posibles, 5 particiones por combinación y 20 entrenamientos realizados



# Modelo Supervisado : Clasificación

---

Evaluación del Modelo:

| Métrica   | Valor   |
|-----------|---------|
| Accuracy  | 99.930% |
| Precision | 65.780% |
| Recall    | 90.200% |
| F1-Score  | 76.080% |
| AUC-ROC   | 99.860% |

# Modelo Supervisado : Clasificación



# Conclusiones

---

El análisis realizado demuestra que las técnicas de minería de datos y aprendizaje automático pueden ser herramientas altamente efectivas para la detección temprana de fraude financiero. Además, la persistencia del modelo permiten su integración en sistemas de monitoreo en tiempo real, contribuyendo a reducir pérdidas económicas y fortalecer la seguridad en los servicios financieros digitales.



# Referencias

---

1. Shafi, A. (2024, 29 febrero). Clasificación de bosques aleatorios con Scikit-Learn. Datacamp. <https://www.datacamp.com/es/tutorial/random-forests-classifier-python>
2. MiniBatchKMeans. (s. f.). Scikit-learn. <https://scikit-learn.org/stable/modules/generated/sklearn.cluster.MiniBatchKMeans.html>
3. Na. (2020, 3 marzo). Clasificación con datos desbalanceados | Aprende Machine Learning. Aprende Machine Learning. <https://www.aprendemachinelearning.com/clasificacion-con-datos-desbalanceados/>
4. BBVA MÉXICO. (2026, 17 marzo). Fraudes financieros: guía para detectar y evitar engaños. <https://www.bbva.mx/educacion-financiera/banca-digital/ciberseguridad/cuenta-digital-fraudes-financieros.html>
5. Data mining for fraud detection. (s. f.). [https://www.meeple.com/en\\_us/topics/data-mining/data-mining-for-fraud-detection](https://www.meeple.com/en_us/topics/data-mining/data-mining-for-fraud-detection)