



UNIVERSIDAD NACIONAL AUTÓNOMA DE MÉXICO

Facultad de Ciencias

Minería de Datos

Profesora: Jessica Santizo Galicia

Diego Antonio Villalba González

Ares Gael Castro Romero

Proyecto Final: Detección de Fraude

Integrantes:

- Emma Alicia Jiménez Sánchez (320046155)
- Nancy Elena del Valle Vera (117001778)
- Leonardo Rafael Ortiz Cervantes(320059362)

Fecha de entrega: 10 de Junio de 2026

Justificación del tema

¿Cuál es el problema?

El fraude financiero representa una de las principales amenazas para la seguridad económica de las personas y las instituciones financieras. Con el crecimiento de los servicios digitales, las transferencias electrónicas y el comercio en línea, los delincuentes han desarrollado mecanismos cada vez más sofisticados para realizar transacciones fraudulentas, ocasionando pérdidas económicas significativas y afectando la confianza de los usuarios en los sistemas financieros.

En este proyecto se analizará el problema de la detección de fraudes en transacciones financieras mediante técnicas de análisis de datos y aprendizaje automático. El objetivo es identificar patrones asociados con actividades fraudulentas a partir de registros históricos de transacciones, permitiendo distinguir entre operaciones legítimas y sospechosas.

¿Por qué es relevante?

La detección de fraudes financieros constituye un problema de gran relevancia social y económica. De acuerdo con datos del Instituto Nacional de Estadística y Geografía (INEGI), el fraude es uno de los delitos más frecuentes en México, afectando a millones de personas cada año y generando pérdidas económicas considerables para los hogares y las instituciones financieras.

Asimismo, los reportes de la Comisión Nacional para la Protección y Defensa de los Usuarios de Servicios Financieros (CONDUSEF) muestran un crecimiento constante de los fraudes cibernéticos, especialmente aquellos relacionados con comercio electrónico, banca móvil y transferencias digitales. Estos delitos representan una parte importante de las reclamaciones presentadas por los usuarios y generan pérdidas que ascienden a miles de millones de pesos anualmente.

La relevancia del análisis radica en que la prevención en tiempo real se ha convertido en una de las herramientas más efectivas para combatir este problema. La capacidad de detectar transacciones sospechosas antes de que se complete el fraude puede reducir significativamente las pérdidas económicas, proteger a los usuarios y fortalecer la confianza en los servicios financieros digitales.

¿Qué se busca lograr?

El objetivo principal de este proyecto es desarrollar un sistema de análisis y monitoreo de transacciones financieras que permita identificar posibles fraudes mediante técnicas de minería de datos y aprendizaje automático.

Para ello, se construirá un dashboard interactivo que facilite la visualización de indicadores relevantes, como la frecuencia de fraudes, la distribución de transacciones y los patrones asociados a actividades sospechosas. Además, se entrenarán y evaluarán distintos modelos de clasificación, agrupamiento y

detección de anomalías con el fin de identificar comportamientos irregulares y comparar el desempeño de diferentes enfoques para la detección de fraudes.

Se espera que el análisis permita obtener conocimiento útil sobre las características de las transacciones fraudulentas y demostrar el potencial de las técnicas de aprendizaje automático para apoyar la prevención temprana de este tipo de delitos.

¿Por qué este dataset?

Para el desarrollo de este proyecto se seleccionó el conjunto de datos *Fraud Detection Dynamics: Financial Transaction*. Debido a la naturaleza sensible y confidencial de la información financiera, no fue posible encontrar bases de datos públicas mexicanas que proporcionaran un volumen suficiente de transacciones reales con etiquetas de fraude adecuadas para el entrenamiento y evaluación de modelos de aprendizaje automático.

El dataset elegido contiene aproximadamente seis millones de registros de transacciones financieras, lo que permite trabajar con una escala cercana a escenarios reales de operación bancaria. Además, incluye información relevante para identificar patrones asociados con actividades fraudulentas y proporciona una cantidad suficiente de ejemplos para aplicar técnicas de clasificación, segmentación y detección de anomalías.

Por estas características, el conjunto de datos resulta pertinente para alcanzar los objetivos planteados, ya que ofrece la información necesaria para estudiar el fenómeno del fraude financiero y desarrollar modelos capaces de detectar comportamientos sospechosos de manera eficiente.

Análisis Exploratorio de Datos (EDA)

El análisis exploratorio de datos (EDA) constituye la primera etapa del proceso analítico y tiene como propósito comprender la estructura, calidad y distribución de los datos antes de aplicar cualquier técnica de modelado. A través de este análisis se identifican posibles problemas en los datos, patrones relevantes y relaciones entre variables que permiten fundamentar las decisiones de preprocesamiento y selección de modelos.

Descripción general del dataset

El conjunto de datos utilizado corresponde al dataset *Fraud Detection Dynamics: Financial Transaction*, obtenido de la plataforma Kaggle. La base de datos contiene información sobre transacciones financieras y fue diseñada para el estudio de técnicas de detección de fraude.

La tabla está compuesta por **6,362,620 registros** y **11 variables**, ocupando aproximadamente **706 MB** de memoria. Las variables incluyen información temporal, montos de transacciones, balances de las cuentas involucradas y etiquetas relacionadas con actividades fraudulentas.

La distribución de tipos de datos es la siguiente:

- 5 variables numéricas de tipo `float64`.
- 3 variables numéricas de tipo `int64`.
- 3 variables categóricas de tipo `string`.

Las variables consideradas para el análisis fueron:

Variable	Tipo	Descripción
step	Numérica	Unidad temporal de la simulación, donde cada paso representa una hora.
type	Categórica	Tipo de transacción realizada.
amount	Numérica	Monto de la transacción.
nameOrig	Categórica	Identificador de la cuenta de origen.
oldbalanceOrg	Numérica	Saldo de la cuenta de origen antes de la transacción.
newbalanceOrig	Numérica	Saldo de la cuenta de origen después de la transacción.
nameDest	Categórica	Identificador de la cuenta destino.
oldbalanceDest	Numérica	Saldo de la cuenta destino antes de la transacción.
newbalanceDest	Numérica	Saldo de la cuenta destino después de la transacción.
isFraud	Binaria	Indica si la transacción fue fraudulenta.
isFlaggedFraud	Binaria	Indicador de fraude generado por reglas del sistema.

Antes de comenzar el análisis se verificó que los nombres de las columnas estuvieran normalizados y que cada variable correspondiera al tipo de dato esperado.

Calidad de los datos

La calidad de los datos fue evaluada mediante la búsqueda de valores faltantes y registros duplicados.

El conteo de valores nulos mostró que ninguna de las columnas presenta datos faltantes. En consecuencia, el porcentaje de valores nulos para todas las variables es del 0%. Asimismo, se realizó una búsqueda de registros duplicados mediante la función `uplicated()`, obteniéndose un total de **0 transacciones duplicadas**.

Dado que no existen valores faltantes ni registros repetidos, no fue necesario aplicar técnicas de imputación o eliminación de observaciones. Esto indica que el conjunto de datos presenta una calidad adecuada para realizar análisis estadísticos y entrenar modelos de aprendizaje automático sin requerir procesos extensivos de limpieza.

Estadísticas descriptivas

Las estadísticas descriptivas revelan una gran variabilidad en las variables financieras analizadas.

El monto promedio de las transacciones es de aproximadamente **179,862 unidades monetarias**, mientras que la mediana es considerablemente menor (**74,872**), lo que sugiere una distribución asimétrica con presencia de transacciones de gran magnitud.

De manera similar, los balances de origen y destino presentan diferencias importantes entre la media y la mediana, indicando distribuciones sesgadas y la existencia de valores extremos. Las desviaciones estándar elevadas observadas en estas variables confirman una alta dispersión de los datos.

Respecto a la variable objetivo, la media de `isFraud` es cercana a **0.1291%**, lo que indica que únicamente una pequeña proporción de las transacciones corresponde a fraudes reales. Esto anticipa un problema de desbalance de clases que deberá considerarse durante el modelado.

Detección de valores atípicos

Para la identificación de valores atípicos se emplearon diagramas de caja (boxplots) utilizando una escala logarítmica. Esta decisión se tomó debido a la elevada dispersión presente en las variables financieras del conjunto de datos. En escenarios transaccionales reales es común que la mayoría de las operaciones correspondan a montos relativamente pequeños, mientras que una proporción reducida alcanza valores considerablemente mayores. Si se utilizara una escala lineal, los valores extremos dominarían la visualización y dificultarían la interpretación del comportamiento de las transacciones más frecuentes.

El análisis de la variable `amount` mostró que la mayoría de las transacciones se concentra dentro del rango intercuartílico, mientras que existe una cantidad importante de observaciones por encima del límite superior definido por la regla IQR. Estos valores representan transacciones de montos excepcionalmente altos que podrían corresponder tanto a operaciones legítimas de gran volumen como a

posibles actividades fraudulentas. Debido a la naturaleza del problema, dichos registros fueron conservados, ya que podrían contener información valiosa para la detección de anomalías.

En las variables relacionadas con los balances de las cuentas (`oldbalanceOrig`, `newbalanceOrig`, `oldbalanceDest` y `newbalanceDest`) también se observó una gran cantidad de valores atípicos. Sin embargo, estos registros son consistentes con la existencia de cuentas corporativas, cuentas de ahorro con elevados montos acumulados o clientes de alto patrimonio. Por esta razón, los valores extremos no fueron eliminados del conjunto de datos y se considerarán durante el proceso de modelado mediante técnicas de escalamiento y transformación adecuadas.

Distribución de las variables numéricas

Los histogramas de las variables numéricas muestran una distribución fuertemente sesgada hacia la derecha. En todas las variables analizadas se observa una alta concentración de registros en valores bajos y una cola larga compuesta por observaciones de gran magnitud.

La variable **amount** presenta una elevada frecuencia de transacciones de montos relativamente pequeños, mientras que las operaciones de gran volumen son menos comunes. Este comportamiento es consistente con los patrones observados en sistemas financieros reales, donde la mayoría de las transacciones corresponden a pagos cotidianos y transferencias ordinarias.

Para la variable `oldbalanceOrig`, el análisis indica que una gran proporción de las cuentas posee saldos relativamente bajos, mientras que un número reducido concentra cantidades significativamente mayores. Este patrón podría asociarse a la coexistencia de usuarios individuales y cuentas con mayor capacidad financiera, como empresas o clientes de alto patrimonio.

En el caso de `newbalanceOrig`, se observa una reducción general de los saldos después de las transacciones, comportamiento esperado debido a la salida de recursos desde las cuentas de origen. No obstante, persisten numerosos valores elevados que indican la existencia de cuentas con grandes reservas financieras incluso después de realizar operaciones.

Las variables `oldbalanceDest` y `newbalanceDest` presentan distribuciones muy similares. Esto puede explicarse porque muchas de las cuentas receptoras ya poseen saldos elevados antes de recibir una transacción, por lo que el monto transferido representa únicamente una pequeña proporción de su balance total. Como resultado, el saldo final mantiene una estructura estadística semejante al saldo inicial.

En conjunto, las distribuciones observadas sugieren la necesidad de aplicar técnicas de transformación o escalamiento de variables antes del entrenamiento de ciertos modelos de aprendizaje automático, con el objetivo de reducir el impacto de la asimetría y mejorar la estabilidad numérica de los algoritmos.

Relaciones entre variables

Para analizar la dependencia entre las variables numéricas se construyó una matriz de correlación utilizando el coeficiente de Spearman.

Las correlaciones más fuertes se observaron entre:

- `oldbalanceDest` y `newbalanceDest` (0.94).
- `oldbalanceOrg` y `newbalanceOrig` (0.80).
- `amount` y `newbalanceDest` (0.67).
- `amount` y `oldbalanceDest` (0.60).

Estas relaciones son coherentes desde una perspectiva financiera, ya que los balances posteriores dependen directamente de los balances iniciales y de los montos transferidos.

Por otro lado, las variables relacionadas con fraude (`isFraud` e `isFlaggedFraud`) presentan correlaciones lineales bajas con el resto de las variables. Este resultado sugiere que la detección de fraude probablemente requiera identificar patrones complejos y no únicamente relaciones lineales simples.

Análisis de variables categóricas y balance de clases

La variable objetivo `isFraud` presenta un fuerte desbalance de clases. Del total de transacciones registradas, aproximadamente el **99.87 %** corresponde a operaciones legítimas, mientras que únicamente el **0.1291%** se encuentra etiquetado como fraude.

Este comportamiento es consistente con los sistemas financieros reales, donde los eventos fraudulentos representan una pequeña fracción del total de operaciones. Sin embargo, este desbalance constituye uno de los principales retos para la construcción de modelos predictivos, ya que un clasificador podría alcanzar una alta exactitud simplemente prediciendo que todas las transacciones son legítimas. Por esta razón, durante el modelado será necesario considerar métricas especializadas y técnicas de manejo de clases desbalanceadas.

Respecto a la variable `type`, se observó que las transacciones de tipo `CASH_OUT` representan la categoría con mayor frecuencia, seguidas por `PAYMENT` y `CASH_IN`. Este resultado es particularmente relevante desde la perspectiva de la detección de fraude, ya que los delincuentes suelen privilegiar ciertos mecanismos de transferencia para maximizar la rapidez con la que pueden disponer de los recursos obtenidos ilícitamente.

Las operaciones de tipo `CASH_OUT` son especialmente importantes debido a que permiten convertir rápidamente fondos digitales en efectivo, reduciendo la posibilidad de rastreo y recuperación de los recursos. Por esta razón, identificar la distribución y frecuencia de los distintos tipos de transacción constituye un elemento clave para comprender los patrones de fraude presentes en el conjunto de datos.

El análisis de las variables categóricas sugiere que el tipo de transacción puede

aportar información valiosa para los modelos de clasificación y detección de anomalías, especialmente cuando se combina con variables relacionadas con montos y balances.

Modelo No Supervisado : Clustering

1. Selección y justificación de variables

Variable	Tipo
step	Numérica
type	Categórica
amount	Numérica
oldbalanceOrg	Numérica
newbalanceOrig	Numérica
oldbalanceDest	Numérica
newbalanceDest	Numérica
isFlaggedFraud	Binaria

Se excluyeron las variables de nameOrig, nameDest y isFraud, ya que con esto el modelo podría estar cayendo en un sobreajuste.

2. Preprocesamiento

Se realizó la **normalización y estandarización** de las variables numéricas debido a la gran disparidad en los montos de las transacciones, evitando así que los valores atípicos o de gran magnitud eclipsaran a las demás características en el modelo. Por otro lado, se excluyeron los nombres de las cuentas de origen y destino, así como la variable objetivo (etiqueta). Esta última se omitió porque el algoritmo no es supervisado, y su inclusión habría provocado un **sobreajuste (overfitting)**. La eliminación de las identidades de las cuentas responde a la necesidad de que el modelo generalice los patrones de fraude en lugar de memorizar entidades específicas; de lo contrario, una cuenta señalada por fraude hoy podría cambiar su comportamiento mañana, invalidando el aprendizaje del modelo. Este filtrado permite un entrenamiento más rápido y una mejor capacidad de generalización.

3. Selección del algoritmo y justificación por qué ese algoritmo es adecuado para los datos

Se seleccionó el algoritmo **MiniBatchKMeans** debido al alto volumen de datos, el cual asciende a 6 millones de registros. Aplicar un algoritmo de clustering tradicional sobre la totalidad de este conjunto no sería óptimo debido a las limitaciones de memoria RAM. MiniBatchKMeans soluciona esto extrayendo aleatoriamente subconjuntos de datos (*batches*) de un tamaño predefinido para entrenar el modelo de forma iterativa. Este enfoque refleja las necesidades del entorno de producción real, donde se procesan millones de transacciones y el entrenamiento masivo es inviable. Además, el algoritmo destaca por su capacidad de **aprendizaje progresivo**, lo que permite incorporar nuevas transacciones y actualizar el modelo continuamente sin necesidad de reentrenarlo desde

cero.

4. Elección del número de grupos

Se escogieron las siguientes métricas para poder evaluar el modelo:

Al no tener los casos de verdaderos positivos y falsos, ya que estamos con un algoritmo de clustering, se utilizaron las siguientes métricas para poder evaluar los grupos, saber si son idénticos, separación de ellos y la distancia que hay entre sus clusters.

Coefficiente de Silueta: 0.6903

Como tenemos que es cercano a 1 estamos teniendo una buena respuesta de agrupamiento, los puntos están muy juntos dentro de su propio grupo y cada grupo está muy lejos y bien separado de los demás. Aun hay mas por mejorar pero se está teniendo un buen resultado.

Inercia (WCSS): 588,564,096.00

Esta métrica nos mide qué tan dispersos están los puntos dentro de sus propios grupos, sin embargo esto debe de estar en un rango de -1 y el infinito, pero se nos dispersa. Esto debido a que se están agrupando datos con valores muy grandes que sería el amount, las distancias al cuadrado se elevan exponencialmente. Además esto podría ser un indicador sobre cómo estar moviendo al número de clusters.

Índice Davies-Bouldin: 0.8070

El Índice Davies-Bouldin mide la relación entre la dispersión intra-clúster y la separación inter-clúster. Un valor menor a 1 indica un agrupamiento eficiente. Esta métrica es clave para delimitar el espacio vacío entre grupos, facilitando la detección de anomalías o datos atípicos en las fronteras. El resultado obtenido de 0.80 demuestra que la distancia entre los centroides es mayor que el tamaño de los clústeres, validando que las agrupaciones están correctamente definidas y compactas

5. Visualización de grupos

Se utiliza PCA porque el objetivo es entender cómo se desplazan los datos a lo largo de los extremos y detectar qué puntos se salen de la norma.


Con PCA:

En PCA, los ejes representan las direcciones de máxima varianza de los datos. Observando la forma en "L" de la distribución, podemos inferir la naturaleza de los componentes.

- Cluster 4: se encuentra como la intersección de nuestra "L" siendo el grupo más denso, compacto y homogéneo. Representa el comportamiento de los valores minions que tenemos en nuestra base de datos siendo así que no tiene anomalías. Son los clientes o procesos estándar y predecibles. Siendo un comportamiento mínimo tanto para el Componente 1 y 2.
- Cluster 3 y 2: estos clusters son grupos de transición entre el cluster 1 y 4, encontrándose con en el mínimo del componente 2 y van aumentando conforme el componente 1 aumenta al cluster 1.
- Cluster 1: Este grupo representa la escala en la primera dimensión, donde este grupo crece a lo largo del eje X manteniendo el eje Y controlado en un mínimo. Tiene una base de transferencias normales muy grande, pero un espacio blanco

gigante de anomalías flotando arriba representando un alto volumen, de transaccionalidad muy extendidas.

- Cluster 0: se encuentra en toda la parte de izquierda de la “L”, donde el grupo se caracteriza por una actividad masiva y exclusiva en el Componente 2, mientras mantienen el Componente 1 al mínimo. La base del clúster es normal y esto se identifica por los círculos, pero a medida que sube el eje Y, el comportamiento se vuelve tan extremo que el modelo lo clasifica casi en su totalidad como **anomalía**. Representa un comportamiento especializado o de uso intensivo de un solo recurso.



Modelo Supervisado : Clasificación

Definición de la Variable Objetivo.

El objetivo del modelo supervisado es predecir la variable *isFraud*, la cual indica si una transacción financiera corresponde a un fraude (1) o a una operación legítima (0). Esta variable fue seleccionada porque representa directamente el problema planteado en el proyecto: detectar actividades fraudulentas antes de que produzcan pérdidas económicas. Al tratarse de una variable binaria, el problema se formula como una tarea de clasificación supervisada.

Preprocesamiento de datos

Antes del entrenamiento se aplicaron las siguientes transformaciones:

- **Codificación de variables categóricas:** La variable *type* fue convertida a representación numérica mediante One-Hot Encoding. Las variables: *nameOrig* y *nameDest* fueron excluidas del entrenamiento debido a su alta cardinalidad y porque representan únicamente identificadores de cuentas sin significado

financiero directo.

- **Transformación de variables numéricas:** Debido a la fuerte asimetría observada durante el EDA, las variables monetarias fueron transformadas utilizando una escala logarítmica: *amount*, *oldbalanceOrg*, *newbalanceOrig*, *oldbalanceDest* y *newbalanceDest*. Posteriormente se aplicó *StandardScaler* para estandarizar los valores.
- **Manejo del desbalance de clases:** El conjunto de datos presenta un fuerte desbalance con 99.87 % transacciones legítimas y 0.1291 % transacciones fraudulentas. Para mitigar este problema se utilizó el parámetro: *class_weight='balanced'* dentro del modelo Random Forest. De esta forma el algoritmo penaliza más los errores cometidos sobre la clase minoritaria.

Selección de variables

Se incluyeron las siguientes variables predictoras:

- *step*
- *type*
- *amount*
- *oldbalanceOrg*
- *newbalanceOrig*
- *oldbalanceDest*
- *newbalanceDest*

Las variables *nameOrig* y *nameDest* fueron excluidas porque son identificadores únicos y podrían introducir ruido sin aportar capacidad predictiva generalizable. Asimismo, la variable *isFlaggedFraud* fue eliminada debido a que representa una regla interna de detección ya existente y podría generar fuga de información (data leakage).

División de los datos

Los datos fueron divididos utilizando una estrategia Hold-Out con 80 % entrenamiento y 20 % prueba. Se utilizó una semilla fija para garantizar reproducibilidad: *random_state = 42*. Además, se empleó estratificación para conservar la proporción de fraudes en ambos conjuntos: *stratify=y*.

Entrenamiento y Persistencia del Modelo.

Para la detección de transacciones fraudulentas se seleccionó un modelo de clasificación basado en Random Forest, debido a su capacidad para modelar relaciones no lineales, su robustez ante valores atípicos y su buen desempeño en problemas de clasificación con variables numéricas y categóricas.

La implementación se realizó siguiendo una arquitectura orientada a objetos, donde las responsabilidades de carga de datos, preprocesamiento, entrenamiento y evaluación fueron encapsuladas en clases independientes. El modelo fue implementado mediante la clase *RandomForestFraudModel*, mientras que el proceso de ajuste de hiperparámetros fue gestionado por la clase *ModelTrainer*.

El conjunto de entrenamiento se utilizó para realizar una búsqueda sistemática de hiperparámetros mediante *GridSearchCV*, empleando validación cruzada estratificada de cinco particiones. Esta estrategia permitió evaluar distintas configuraciones del modelo conservando la proporción original de transacciones fraudulentas y legítimas en cada partición. Los hiperparámetros evaluados fueron:

model__n_estimators: [100, 200] (número de árboles que tendrá el bosque).
model__max_depth: [10, 20] (la profundidad máxima de cada árbol.).

En total se evaluaron cuatro configuraciones diferentes del modelo, cada una validada mediante cinco particiones, resultando en veinte entrenamientos independientes. La selección del mejor modelo se realizó utilizando el F1-Score como criterio de optimización, debido al fuerte desbalance presente en el conjunto de datos. Esta métrica permite equilibrar precisión y sensibilidad, siendo especialmente adecuada para problemas de detección de fraude donde los falsos negativos representan un costo elevado.

Una vez identificada la mejor configuración de hiperparámetros, el modelo óptimo fue reentrenado automáticamente utilizando todos los datos del conjunto de entrenamiento. Posteriormente, dicho modelo fue evaluado sobre el conjunto de prueba independiente para estimar su capacidad de generalización sobre datos no observados durante el entrenamiento.

Finalmente, el modelo fue almacenado en disco utilizando la biblioteca *joblib*, permitiendo su reutilización posterior dentro del sistema de monitoreo y detección de fraudes en tiempo real sin necesidad de repetir el proceso de entrenamiento.

Evaluación del modelo

Dado que el problema de detección de fraude presenta un fuerte desbalance de clases, donde las transacciones fraudulentas representan una fracción muy pequeña del total de registros, métricas como la exactitud (*Accuracy*) pueden resultar engañosas. Por esta razón, las métricas más relevantes para evaluar el desempeño del modelo son el *Recall* y el *F1-Score* de la clase fraude. El *Recall* mide la capacidad del modelo para identificar correctamente las transacciones fraudulentas, mientras que el *F1-Score* proporciona un equilibrio entre precisión y sensibilidad. Adicionalmente, se reportan las métricas de *Accuracy*, *Precision* y *AUC-ROC* para obtener una evaluación integral del modelo.

El modelo Random Forest optimizado mediante búsqueda en cuadrícula obtuvo los siguientes resultados sobre el conjunto de prueba:

Métrica	Valor
Accuracy	0.9993
Precision	0.6578
Recall	0.9020
F1-Score	0.7608
AUC-ROC	0.9986

La exactitud o accuracy alcanzó un valor de **99.93%**, indicando que la gran mayoría de las transacciones fueron clasificadas correctamente. Sin embargo, debido al fuerte desbalance de clases presente en el conjunto de datos, esta métrica no es suficiente para evaluar la capacidad real del sistema para detectar fraude.


La precisión obtenida fue de **65.78%**, lo que significa que aproximadamente dos de cada tres transacciones marcadas como fraudulentas efectivamente correspondían a un fraude

real. Aunque existe una proporción de falsos positivos, este comportamiento es relativamente aceptable en sistemas de detección de fraude, donde suele ser preferible investigar algunas operaciones legítimas adicionales antes que permitir que una transacción fraudulenta pase desapercibida.

El modelo alcanzó un **Recall de 90.20%**, siendo esta una de las métricas más importantes del proyecto. Esto implica que el sistema logra identificar correctamente más de nueve de cada diez fraudes presentes en los datos. Desde la perspectiva del negocio, este resultado es especialmente valioso, ya que reduce significativamente la cantidad de operaciones fraudulentas que podrían ocasionar pérdidas económicas.

El **F1-Score de 76.08%** refleja un equilibrio adecuado entre precisión y sensibilidad. Este resultado indica que, aunque el modelo genera algunos falsos positivos, mantiene una alta capacidad para detectar fraudes reales, logrando un compromiso razonable entre minimizar pérdidas económicas y evitar alertas innecesarias.

La curva ROC obtuvo un **AUC de 0.9986**, valor extremadamente cercano a 1.




Este resultado indica una capacidad sobresaliente para discriminar entre transacciones legítimas y fraudulentas. En términos prácticos, el modelo es capaz de asignar consistentemente puntuaciones de riesgo más altas a los fraudes que a las transacciones normales. La forma de la curva ROC, muy cercana al vértice superior izquierdo, confirma que el modelo mantiene simultáneamente una alta tasa de verdaderos positivos y una baja tasa de falsos positivos.

Como línea base se considera un clasificador trivial que siempre predice la clase mayoritaria (*no fraude*). Dicho clasificador alcanzaría una exactitud cercana al **99.87%**, pero tendría una precisión, recall y F1-score de 0, ya que no detectaría ningún fraude.

En contraste, el modelo Random Forest logró identificar más del **90% de los fraudes presentes en los datos**, obteniendo un **F1-Score de 76.08%** y un **AUC de 99.86%**, superando ampliamente el desempeño de la línea base y demostrando su utilidad práctica para la detección temprana de operaciones sospechosas.

La matriz de confusión obtenida fue la siguiente:




A partir de estos resultados se observa que:

- **1,270,110 transacciones legítimas** fueron clasificadas correctamente.
- **1,482 fraudes reales** fueron detectados exitosamente.
- **161 fraudes** no fueron identificados por el modelo (falsos negativos).
- **771 transacciones legítimas** fueron marcadas erróneamente como fraude (falsos positivos).

Desde la perspectiva de la detección de fraude, los falsos negativos constituyen el error más costoso, ya que representan operaciones fraudulentas que lograron pasar inadvertidas. En este caso, únicamente **161 de los 1,643 fraudes presentes en el conjunto de prueba no fueron detectados**, lo que explica el elevado valor de Recall obtenido. Por otro lado, los **771 falsos positivos** representan transacciones legítimas que requerirían una revisión adicional o una validación por parte del usuario. Considerando el volumen total de más de 1.27 millones de transacciones evaluadas, esta cantidad resulta relativamente pequeña y constituye un compromiso razonable para mantener una alta capacidad de detección.

Arquitectura y diagrama UML



La justificación del patrón de Pipeline es:

-La modularidad: Cada filtro es independiente y reutilizable. Se pueden probar, mantener y modificar sin afectar otros componentes.

-Un mejor mantenimiento: Cada nodo tiene una única responsabilidad: limpiar, entrenar, evaluar o reportar.

-Reutilización: Los modelos entrenados se guardan y se pueden reutilizar sin necesidad de re entrenar. Los datos procesados se reutilizan automáticamente.

-Versionado y reproducción: El DataCatalog y los parámetros garantizan que los mismos inputs siempre producen los mismos outputs. Los modelos versionados permiten reproducir predicciones.

Reutilización del Modelo

En nuestro sistema, el modelo se entrena una vez, se guarda y se reutiliza para cualquier predicción futura.

El modelo se define en el catálogo de datos. El atributo `versioned: true` permite mantener múltiples versiones del modelo. Kedro automáticamente añade un timestamp a cada versión guardada. Durante el entrenamiento, el modelo se guarda automáticamente cuando el nodo completa `train_clustering_model` (por ejemplo).

La forma en que se puede reutilizar es simplemente pasar el modelo entrenado como input a otro nodo, esto en `pipeline.py`.

Las ventajas de esto es la eficiencia ya que no se hacen entrenamientos excesivos.

Conclusiones del EDA

El análisis exploratorio permitió determinar que el conjunto de datos posee una alta calidad, ya que no presenta valores faltantes ni registros duplicados. Asimismo, se identificó una fuerte asimetría en las variables financieras, presencia de valores extremos y un importante desbalance entre transacciones legítimas y fraudulentas.

Los resultados obtenidos sugieren la necesidad de aplicar técnicas de escalamiento y transformación de variables antes del modelado. Además, debido a la baja proporción de fraudes, será necesario emplear estrategias específicas para manejar el desbalance de clases. Finalmente, las correlaciones observadas indican que los balances y montos de las transacciones contienen información relevante para la construcción de modelos predictivos orientados a la detección de fraude.

Referencias

1. Shafi, A. (2024, 29 febrero). Clasificación de bosques aleatorios con Scikit-Learn. Datacamp.
<https://www.datacamp.com/es/tutorial/random-forests-classifier-python>
2. MiniBatchKMeans. (s. f.). Scikit-learn.
<https://scikit-learn.org/stable/modules/generated/sklearn.cluster.MiniBatchKMeans.html>
3. Na. (2020, 3 marzo). Clasificación con datos desbalanceados | Aprende Machine Learning. Aprende Machine Learning.
<https://www.aprendemachinelearning.com/clasificacion-con-datos-desbalanceados/>
4. BBVA MÉXICO. (2026, 17 marzo). Fraudes financieros: guía para detectar y evitar engaños.
<https://www.bbva.mx/educacion-financiera/banca-digital/ciberseguridad/cuenta-digital-fraudes-financieros.html>
5. Data mining for fraud detection. (s. f.).
https://www.meegle.com/en_us/topics/data-mining/data-mining-for-fraud-detection